

Pipeline EGFR FASTA: descarga, análisis, gráficas y GitHub privado

Este documento acompaña un repositorio reproducible para descargar secuencias FASTA de EGFR humano, calcular estadísticas básicas y generar gráficas sencillas. Está pensado para ejecutarse desde terminal en Linux, macOS, WSL o Git Bash.

1. Estructura del repositorio

```
egfr_fasta_pipeline/
|-- config/           # Parametros editables del pipeline
|-- scripts/         # Scripts Bash y Python
|-- data/
|   |-- raw/         # FASTA descargados
|   |-- processed/   # Tablas CSV generadas
|-- results/         # Resúmenes de texto
|-- figures/         # Gráficas PNG
|-- docs/            # Instrucciones PDF/Markdown
|-- logs/            # Bitácoras de ejecución
|-- requirements.txt
|-- environment.yml
`-- README.md
```

2. Requisitos

Instalar Git, Python 3.10 o superior, curl y, de preferencia, conda. Para crear el repositorio privado desde terminal se recomienda GitHub CLI, usando el comando gh.

3. Crear el ambiente

Opción A: conda

```
conda env create -f environment.yml
conda activate egfr-fasta-pipeline
```

Opción B: venv

```
python3 -m venv .venv
source .venv/bin/activate
pip install -r requirements.txt
```

4. Ejecutar el pipeline

Desde la raíz del repositorio, ejecute:

```
bash scripts/run_pipeline.sh
```

También puede ejecutarlo por pasos:

```
bash scripts/01_download_egfr_fasta.sh
bash scripts/02_analyze_egfr.sh
```

5. Qué hace cada script

Archivo	Función
config/egfr_config.env	Define EGFR, accession UniProt P00533 e identificador NCBI NM_005228.
scripts/01_download_egfr_fasta.sh	Descarga FASTA de proteína desde UniProt y FASTA de mRNA desde NCBI EFetch.
scripts/analyze_fasta.py	Lee FASTA, calcula longitud, composición, GC o propiedades simples de proteína y genera figuras.

scripts/02_analyze_egfr.sh	Ejecuta el análisis para proteína y mRNA usando la configuración.
scripts/run_pipeline.sh	Orquesta todo el flujo y guarda una bitácora en logs/pipeline.log.

6. Salidas esperadas

```
data/raw/EGFR_protein_P00533.fasta
data/raw/EGFR_mRNA_NM_005228.fasta
data/processed/EGFR_protein_sequence_stats.csv
data/processed/EGFR_protein_composition.csv
data/processed/EGFR_mRNA_sequence_stats.csv
data/processed/EGFR_mRNA_composition.csv
results/EGFR_protein_summary.txt
results/EGFR_mRNA_summary.txt
figures/EGFR_protein_lengths.png
figures/EGFR_protein_composition.png
figures/EGFR_mRNA_lengths.png
figures/EGFR_mRNA_composition.png
```

7. Revisar resultados

```
ls data/processed
cat results/EGFR_protein_summary.txt
cat results/EGFR_mRNA_summary.txt
ls figures
```

8. Inicializar Git

Ejecute estos comandos desde la raíz del proyecto:

```
git init
git branch -M main
git status
git add .
git commit -m "Initial EGFR FASTA pipeline"
```

9. Crear repositorio privado en GitHub

Opción recomendada: GitHub CLI

```
gh auth login
gh repo create egfr-fasta-pipeline --private --source=. --remote=origin --push
```

El argumento `--private` crea un repositorio privado. El argumento `--source=.` usa la carpeta actual, `--remote=origin` agrega el remoto y `--push` sube el primer commit.

Opción alternativa: interfaz web

Cree un repositorio privado vacío desde GitHub, copie la URL HTTPS o SSH y ejecute:

```
git remote add origin URL_DEL_REPOSITORIO
git push -u origin main
```

10. Ciclo de trabajo recomendado

```
git status
git add scripts README.md docs config
git commit -m "Describe el cambio realizado"
git push
```

Si las salidas son pequeñas y desea versionarlas, también puede agregar resultados y figuras:

```
git add results figures data/processed
git commit -m "Add updated EGFR analysis outputs"
git push
```

11. Cambiar a otro gen o proteína

Edite `config/egfr_config.env`. Por ejemplo:

```
GENE_SYMBOL="EGFR"
UNIPROT_ACCESSION="P00533"
NCBI_NUCCORE_ID="NM_005228"
```

Para otro objetivo use un accession válido de UniProt para la proteína y un identificador válido de NCBI Nucleotide para el FASTA nucleotídico.

12. Buenas prácticas

No suba datos grandes o sensibles. Mantenga el código en `scripts`, las tablas procesadas en `data/processed`, los resúmenes en `results` y las imágenes en `figures`. Use mensajes de commit descriptivos y revise siempre `git status` antes de confirmar cambios.

13. Fuentes técnicas consultadas

GitHub CLI: https://cli.github.com/manual/gh_repo_create

GitHub Docs: <https://docs.github.com/en/migrations/importing-source-code/using-the-command-line-to-import-source-code/adding-locally-hosted-code-to-github>

NCBI E-utilities: <https://www.ncbi.nlm.nih.gov/books/NBK25499/>

UniProt programmatic access: https://www.uniprot.org/help/programmatic_access